

2026香港 ITF 论文

Cognitive Revenue Management: Synergizing Specialized Learning&Inference Models and AI Agents for the New Era of Tourism Policy and Market Dynamics

一个适配旅游新策略和动态市场的认知型收益管理智能协同系统

一、项目背景与意义

（一）国家与香港旅游产业进入“高质量发展”新阶段

近年来，国家持续推进高水平对外开放战略，并不断优化国际人员往来政策。中国已陆续对多个国家实施或扩大免签政策，持续提升国际旅客入境便利化水平。与此同时，《“十四五”旅游业发展规划》明确提出，要推动旅游业由规模扩张向质量提升转变，提升旅游服务供给质量与数字化治理能力，建设智慧旅游和智慧服务体系。

香港作为国际旅游中心城市及粤港澳大湾区的重要节点，也正迎来旅游业全面复苏与高质量发展的关键阶段。香港特区政府最新公布的《旅游业发展蓝图2.0》及《Hong Kong: The Facts – Tourism》明确提出：

- 巩固香港国际旅游枢纽地位；
- 发展高质量旅游体验（Quality Tourism Experience）；
- 推动智慧旅游（Smart Tourism）；
- 重点发展文化旅游、体育旅游、生态旅游及大型活动旅游（Mega Event Tourism）；
- 吸引更多高价值过夜旅客（High Value-added Overnight Visitors）。

2024年旅游业增加值约占香港GDP的2.8%，为香港提供约15.97万个就业岗位，占整体就业人口约4.3%。进入2025年后，香港旅游业持续复苏。全年访港旅客约4,990万人次，同比增长约12%；其中约3,780万人次来自内地市场，约1,210万人次来自国际及其他市场。同期香港酒店平均入住率进一步提升至87%，高于2024年的85%，显示旅游消费需求及住宿市场持续回暖。

然而，旅游消费模式正在发生深刻变化：

- 游客更加价格敏感（比如2025年全年，中国大陆游客中通过 IVS 入境的比例已达57%）；
- 预订行为更加动态化和临时化；
- 演唱会、展会、体育赛事等大型活动对需求影响显著增强；
- OTA平台和数字渠道加速改变酒店收益结构；

- 市场波动性和不确定性显著提升。

旅游产业面临的核心挑战已经从“吸引游客来港”逐渐转变为，

如何更精准理解需求变化、提升旅游产品收益管理能力、优化有限旅游资源配置，并提高单位游客经济贡献（Value per Visitor）。

这为人工智能驱动的认知收益管理（Cognitive Revenue Management）和决策智能平台（Decision Intelligence Platform）提供了重要的发展机遇和现实需求。

（二）从传统RMS走向CRM(Cognitive Revenue Management)

目前全球主流酒店收益管理系统（Revenue Management System, RMS）主要基于历史销量、价格及入住率进行预测。

这类系统虽然能够回答：

“未来可能卖多少？”

但无法回答：

- 市场为什么发生变化？
- 当前需求变化来自哪些因素？
- 客户愿意支付多少溢价？
- 当前库存应该保留还是释放？
- 在复杂市场状态下最优收益策略是什么？

随着旅游市场受到天气、交通、演唱会、展览活动、社交媒体舆情以及国际政策变化等多种因素共同影响，仅依赖销量预测已无法支撑高质量决策。

因此，本项目提出从传统 Forecasting System（预测系统）向 Demand Understanding System（需求认知系统）进一步升级，并最终构建面向旅游服务业的：

Cognitive Revenue Management

其核心思想为：

- Regime Model 识别市场正在发生什么；
- Causal AI 解释为什么发生；
- Price Elasticity 理解客户愿意支付多少；
- Operations Research 优化库存配置；
- Reinforcement Learning 学习长期收益最优策略。

通过构建市场状态认知、需求理解与收益决策的一体化体系，实现酒店收益管理从“预测驱动”向“决策驱动”的范式转变。

（三）对香港旅游产业升级的价值

本项目不仅服务于单一酒店企业，更可成为香港旅游服务业数字化升级的重要基础设施。

首先，本项目将帮助香港酒店业从经验驱动经营模式向数据驱动与智能决策模式升级。

其次，项目将提升香港旅游产品的收益管理能力和资源配置效率，推动旅游产业从“增加客流”向“提升单位游客价值（Value per Visitor）”转型。

第三，项目能够支撑香港发展高质量旅游产品，包括：

- 会展旅游（MICE）
- 邮轮旅游
- 演唱会经济
- 体育赛事经济
- 主题活动旅游

通过更精准的定价和库存管理，提高旅游资源利用效率。

第四，项目将推动香港人工智能、数据科学与旅游科技（TravelTech）产业融合发展，形成具有香港特色的智慧旅游技术能力。

（四）跨行业推广价值

本项目提出的核心框架并不局限于酒店行业。

酒店房晚、机票座位、演唱会门票、高铁车票、邮轮舱位、本地活动门票等均具有共同特征：

- 库存具有时效性；
- 过期即失效；
- 需求具有不确定性；
- 存在动态定价需求；
- 存在库存配置问题。

因此，本项目形成的：

Cognitive Revenue Management based on the orchestration of specialized models and AI large language models（基于专业模型和大模型协同的认知型收益管理系统）

可进一步推广至：

- 航空收益管理

- 邮轮收益管理
- 演唱会票务管理
- 体育赛事票务管理
- 高铁与交通票务管理

形成面向服务经济的新一代智能收益管理平台。

（五）社会效益与企业效益

社会效益

- 提升香港旅游服务业数字化水平；
- 提高旅游资源利用效率；
- 支撑高质量旅游发展战略；
- 推动AI技术在实体服务业落地；
- 培育旅游科技（TravelTech）创新生态。

企业效益

对于大型酒店集团：

- 提供专业收益管理与市场洞察能力；
- 提升RevPAR与经营效率；
- 降低库存浪费与收益损失。

对于香港中小酒店及旅游企业：

- 提供低门槛、平台化智能收益管理服务；
- 缩小与国际大型酒店集团之间的数字化能力差距；
- 提升市场竞争力和盈利能力。

最终形成“香港研发、湾区验证、国际推广”的智慧旅游创新解决方案。

二、研究内容与技术路线

本项目构建面向酒店行业的 Cognitive Revenue Management（认知型收益管理）体系，并形成可面向酒店企业、中小旅游服务商及相关票务行业推广的 Decision Intelligence Platform（决策智能平台）。项目不再将酒店收益管理简单理解为“基于历史数据预测未来销量”，而

是围绕酒店经营中的真实决策过程，建立一套**感知外部环境、理解需求变化、优化价格与库存配置，并支持 Learning& Inference Models 和 AI Agents 协同决策的新型技术体系**。

在新的旅游政策、国际客流恢复、大型活动经济兴起以及游客行为快速变化的背景下，酒店经营面临的不确定性显著增强。价格不再只由历史入住率决定，需求也不再只是历史订单的自然延续。**演唱会、体育赛事、会展活动、节假日、社交媒体传播、城市舆情、交通变化和入境政策变化，都可能在短时间内改变一个城市、一个商圈甚至一家酒店的需求结构**。传统 RMS 虽然在成熟稳定市场中具有一定作用，但在这种动态环境下，往往会因为只依赖历史交易数据而出现预测滞后、事件识别不足和价格反应不及时等问题。

因此，本项目的研究路线将从“事件感知与需求认知”出发，再进入“收益定价与库存优化”，最终形成面向酒店经营者的智能决策支持能力。整体研究将回答三个核心问题：

第一，如何在不完整、偏差化和滞后的市场观测条件（Big Event + Social Data）下理解真实需求，即 Demand Understanding under Sparse and Biased Observations。

第二，如何在市场不确定、价格受限、库存有限和风险约束共存的条件下实现收益优化，即 Revenue Optimization under Uncertainty and Constraints。

第三，如何将 Learning&Inference Models 与 AI Agents 结合，使系统不仅能够计算最优策略，还能够解释原因、辅助运营人员判断并持续学习，即 Decision Intelligence with Human-AI Collaboration。

围绕上述问题，本项目对以下四个方面进行算法研究、工程落地和商业价值转化。

2.1 数据与事件认知模型

数据与事件认知模型是本项目区别于传统酒店收益管理系统的关键基础，也是整个技术路线中最重要的创新起点。

传统收益管理理论大多建立在相对稳定的历史交易数据基础上，假设未来需求可以从过去的入住率、价格、销量和季节性规律中推断出来。然而，在当前香港及大湾区旅游市场中，这一假设正在被快速打破。旅游需求越来越多地受到外部事件和社会行为的影响，例如演唱会带来的短期住宿需求爆发，展会带来的商务客集中入住，体育赛事带来的区域性房源紧张，社交媒体内容传播带来的目的地热度上升，以及入境便利化政策带来的游客结构变化。

这些因素在传统模型中往往只被处理成简单的“是否有事件”或“节假日标记”，但这种处理方式远远不够。本项目将把“数据与事件认知模型”作为认知型收益管理体系的第一层能力。模型包括两个部分：

- Big Event Intelligence 负责识别可结构化的大型事件冲击；
- Social Data Intelligence 负责刻画事件传播强度、游客情绪变化和非结构化弱需求信号。

同时 Social Data 再区分 A. Event-related Social Data 围绕大事件的传播与情绪信号 和 B. Non-event Social Data 非大事件驱动的零散、微弱、长尾需求信号。第一类用于增强 Big

Event 模型，判断事件强度、扩散范围和真实需求转化；第二类用于发现传统事件日历看不到的市场变化，比如某个岛突然被短视频带火、某家酒店因网红内容爆红、某区域评价变差导致需求转移。

Big Event 和 Social Data 二者不是替代关系，而是共同构成对区域酒店供需关系的多层感知能力。其目标是建立外部事件、社会信号与酒店真实需求之间的可解释映射机制（认知过程），使系统能够更早理解市场变化，并将这种理解传递给后续的价格弹性模型、动态定价模型和库存管理模型。

2.1.1 Big Event 驱动的需求认知模型

演唱会、体育赛事、展览会议、节庆活动和城市庆典往往会在短时间内显著改变酒店需求结构，尤其会影响活动场馆周边区域、交通便利区域以及特定价格带酒店的预订行为。

现有收益管理系统在处理大型活动时通常存在两个不足。第一，只识别事件是否发生，而不理解事件强度。第二，只把事件作为统一变量输入模型，而不因果推断它对不同区域、不同酒店、不同房型和不同客群的影响差异。结果是，在真正的需求爆发到来之前，系统往往没有及时识别价格上行机会；而在事件热度被高估时，又容易出现过度涨价和库存滞销。

本项目构建 Big Event Cognitive Framework，将专家知识与数据驱动学习结合起来，对各类事件及造成的需求影响进行因果关系和因果效应刻画。系统不再只是知道“某天有演唱会”，而是能够进一步判断“这场演唱会如何影响酒店定价和库存、影响多久、可能带来多少需求变化、客人愿意接受多高溢价”等。这些认知结果将被动态传递给后续定价和库存模型，让其能够随事件变化而调整。

这部分是本项目的重要亮点之一。它弥补了传统收益管理理论对大型事件刻画不足的问题，使酒店收益管理能够更适应香港未来重点发展的 Mega Event Tourism、会展经济、演唱会经济和体育旅游场景。

工程落地和商业价值

项目将建设 Event Detection → Regime Recognition → Demand Impact Modeling 的统一事件认知引擎，在大型活动、会展旅游、演唱会经济等高波动场景下，进一步释放传统 RMS 难以捕捉的收益机会。并将通过落地采集以下技术指标和商业指标，来验证决策质量提升 (Decision Quality Improvement) 的潜力：

- 提升大型活动期间的价格响应速度
- 提升需求峰值识别准确率
- 降低需求突变导致的定价滞后
- 提升库存配置效率
- 提升RevPAR及总收益表现

2.1.2 Social Data 驱动的需求映射模型

除大型活动外，社交媒体和线上内容传播正在成为影响旅游需求的重要力量。游客在选择目的地、酒店和出行时间时，越来越多地受到短视频、社交平台、搜索指数、用户评价和城市话题热度影响。尤其对于年轻游客和自由行游客，线上内容往往会在正式预订之前先改变目的地偏好和出行意愿。

但社会数据的使用难点在于，它不是天然等于需求。社交媒体热度可能代表真实出行意愿，也可能只是短期关注；搜索量上升可能意味着未来预订增长，也可能只是信息查询；用户评价变化可能影响酒店转化率，也可能只影响极少部分客群。因此，如果仅将社交热度、搜索指数和评价数据作为普通相关性特征输入模型，系统很容易被噪声误导。

本项目构建 Social Data to Demand Mapping Model，区分两部分内容：

A. Event-related Social Data 围绕大事件的传播与情绪信号

举个例子，演唱会本身属于 Big Event，但演唱会引发的讨论属于 Social Data，它补充 Big Event 无法回答的问题：

这场演唱会到底热不热？

热度有没有破圈？

观众是不是外地游客？

讨论是在看热闹，还是已经开始订酒店？

影响是集中在场馆附近，还是扩散到全城？

B. Non-event Social Data 非大事件驱动的零散、微弱、长尾需求信号

发现传统事件日历看不到的市场变化，比如某个岛突然被短视频带火、某家酒店因网红内容爆红、某区域评价变差导致需求转移等。

技术实现上，构建 LLM / NLP → 因果分析 → 概率图 / 状态空间模型的 Social Data Intelligence Engine。LLM 负责读出信号，因果负责判断真假影响，动态模型负责描述影响如何传导到供需关系。具体来说，

1) LLM 负责从小红书、评论、攻略、新闻中抽取目的地/商圈/酒店名、事件名称、情绪正负面、出行意图强弱、价格抱怨、库存紧张感、交通便利性等特征；

2) 借鉴意图识别和检索的概念，使用 AI 大模型 + 因果分析把非结构化文本变成原因表征，这些指标进入因果模型和时序模型，完成 Latent Travel Intent Recognition。适合回答比如“小红书住宿意图热度上升是否仍然会带来未来订单增长？”、“搜索指数上涨是订单增长的前因，还是订单增长后的同步表现？”、“评论情绪变差是否导致该酒店转化率下降，还是因为酒店涨价后客人同时差评和流失？”类似问题。

3) Travel Intent → Booking Intent 两个隐变量的状态迁移，代表了游客需求形成过程中的潜在行为状态（Latent Behavioral States），想从 Social Data 学习中获得，但它们并非可直接

观测变量。本项目将采用动态贝叶斯网络（Dynamic Bayesian Network）和隐状态模型（Hidden State Models），利用社交媒体热度、搜索行为、OTA浏览行为及历史订单数据，对潜在状态进行联合学习和实时推断。在训练阶段，系统基于历史行为数据学习状态转移规律；在运行阶段，系统根据最新观测信号实时推断当前市场所处的需求状态，从而实现对未来需求变化和供需关系演化的提前感知。

训练阶段：学习

$$P(\text{Travel Intent}_t \mid \text{Travel Intent}_{t-1}, \text{Social}_t)$$

$$P(\text{Booking Intent}_t \mid \text{Travel Intent}_t)$$

$$P(\text{Order}_t \mid \text{Booking Intent}_t)$$

参数由历史数据估计。

推理阶段：观察到 小红书热度上升、Google搜索上升、OTA浏览上升后，模型实时推断：

$$P(\text{Travel Intent} = \text{High}) = 87$$

$$P(\text{Booking Intent} = \text{High}) = 73$$

总结来说，Social Data 并不直接预测订单，而是作为市场需求形成过程中的上游观测信号。项目将利用动态贝叶斯网络（Dynamic Bayesian Network）、状态空间模型（State Space Model）以及因果推断方法，刻画社会信号从“关注（Attention）→ 出行意图（Travel Intent）→ 预订意图（Booking Intent）→ 实际需求（Demand）→ 供需关系（Supply-Demand Dynamics）”的动态传导机制。

模型中间阶段会输出简单热度指标（下图），但最终输出区域需求强度、需求增长概率、预订窗口变化趋势以及市场紧张度等可直接服务于收益管理决策的认知指标。

Destination Buzz Index	目的地热度指数
Travel Intent Score	出行意愿指数
Accommodation Intent Score	住宿预订意愿指数
Price Sensitivity Signal	价格敏感度指数
Negative Sentiment Score	负面舆情指数
Event Spread Score	事件传播影响指数
Out-of-town Visitor Signal	跨区域游客流入指数

商业价值

构建出 Social Demand Intelligence Indicators（社会需求认知指标体系），认知：

- 需求预测误差下降
- 提前发现需求拐点
- 提高动态定价反应速度

2.2 收益定价模型（Revenue Pricing Models）

酒店经营的核心问题之一是如何在不同市场状态、库存状态和需求状态下实现收益最大化。传统收益管理系统通常采用规则驱动或简单预测驱动方式进行调价，缺乏对客户支付意愿、市场状态及长期收益的综合考虑。本项目将围绕不同决策层次构建三类定价模型。

2.2.1 基于因果推断的动态价格弹性最优定价模型

价格弹性是连接市场需求与价格决策的重要桥梁。在利用历史交易数据进行策略分析时，传统的观测数据往往受到内生性混淆偏差的剧烈干扰，仅靠关联性分析难以准确识别出价格变动对订单转化行为的纯粹边际效应。本研究引入因果推断方法建立酒店价格弹性学习框架，其核心价值在于超越表面的统计相关性，将价格调整视为主动实施的因果干预，利用正交化去偏技术科学剥离复杂的外部混淆因素，从而在解耦后的空间中精准捕捉价格变化对需求反馈的真实因果效应。

为了满足复杂多变的市场环境与时决策需求，本模型全面结合市场状态（Regime）、预订窗口（Booking Window）、客群特征以及历史交易行为，形成了随上下文实时漂移的动态价格弹性模型。该架构将多维时空特征同时作为混淆变量与效应修饰变量引入，利用双重残差正交化思想，通过机器学习模型提取出排除常规规律后的价格残差与销量残差。这一机制使得复杂的非线性基准需求在数学上被有效偏出，全面释放了模型对时空异质性的感知能力，实现了价格弹性系数随市场情境变化的动态演化。

基于这一无偏的因果推理架构，系统能够针对不同酒店、不同房型及不同市场状态自动化构建精准的需求曲线与收益曲线，实现从经验定价向科学定价的跨越转变。该模型不仅能够清晰量化并精准回答“价格上涨后销量会下降多少”这一经典的反事实干预问题，科学模拟出未发生的价格路径对销量的真实反噬程度；更能够超越单纯的销量预测，通过对实时生成的期望收益曲线进行数学寻优，直接解算出“当前市场状态下的最优收益价格是多少”，从而赋予系统敏锐识别最佳提价窗口或降价对冲库存风险的高阶决策能力。

动态价格弹性公式推导

需求的基准规模和价格敏感度同时受到多维情境特征（如市场状态（Regime）、预订窗口（Booking Window）、客群特征以及历史交易行为）的调制。因此，供需方程设定为：

$$Q = \alpha(X) \cdot P^{\theta_0(X)} \cdot \zeta \quad (1)$$

- Q : 需求量 (Quantity Demanded)
- P : 价格 (Price)
- X : 混淆与效应修饰变量集合 (Contextual Features Vector)
 - 是一个高维的时空上下文特征向量，由系统底层引擎 (L1-L5) 实时输出并传入。在本项目中，它精准映射为：市场状态 (Regime)、预订窗口 (Booking Window)、客群特征以及历史交易行为的综合表征。
- $\alpha(X)$: 基准需求规模函数 (Baseline Demand Scale Function)
 - 是一个关于上下文特征 的未知非参数乘数函数。它决定了在完全不考虑价格因素时，当前的市场状态、预订窗口等外部环境所决定的底层大盘自然销量水位（即乘法模型中的基准规模）。
- $\theta_0(X)$: 动态价格弹性函数 (Dynamic Price Elasticity Function)
 - 指数 天然且直观地代表了特定情境 下的价格弹性系数。它代表当处于特定的市场状态或预订窗口切片时，“价格每变动，销量变动的百分比”。它直接决定了当前决策瞬间因果需求曲线的斜率和收益抛物线的开口弧度。
- ζ : 乘性随机扰动项 (Multiplicative Error Term)
 - 表示历史策略中未被系统观测到的随机外部冲击与市场白噪声（例如突发的天气变动、未被捕获的竞对临时降价促销等）。

对这个泛化后的经济学方程（式 1）求关于价格 的点弹性。根据微观经济学定义，在给定的市场上下文 下：

$$\text{Elasticity}(X) = \frac{\partial Q}{\partial P} \cdot \frac{P}{Q}$$

将式 (1) 代入求导：

$$\frac{\partial Q}{\partial P} = \alpha(X) \cdot \theta_0(X) \cdot P^{\theta_0(X)-1} \cdot \zeta$$

$$\text{Elasticity}(X) = \left[\alpha(X) \cdot \theta_0(X) \cdot P^{\theta_0(X)-1} \cdot \zeta \right] \cdot \frac{P}{\alpha(X) \cdot P^{\theta_0(X)} \cdot \zeta} = \theta_0(X)$$

弹性系数不再是一个僵化的常数，而是完美蜕变为了一个由市场状态、预订窗口等特征 实时驱动的动态因果效应函数。

对式 (1) 两边同时取自然对数（ $\log$ ）：

$$\log Q = \log \left(\alpha(X) \cdot P^{\theta_0(X)} \cdot \zeta \right)$$

$$\log Q = \log \alpha(X) + \theta(X) \cdot \log P + \log \zeta$$

(2)

令 $Y = \log Q$, $T = \log P$, 并令 $g_0(X) = \log \alpha(X)$, $\epsilon = \log \zeta$

根据上述对数化变换, 我们将动态定价问题建立为如下部分线性结构方程 (Partial Linear Structural Equation) :

$$Y = \theta_0(X) \cdot T + g_0(X) + \epsilon \quad (3)$$

两边同时取关于混淆变量 X 的条件期望

为了消除不可观测且高度非线性的基准需求干扰项 $g_0(X)$, 我们根据弗里希-沃-洛维尔 (FWL) 定理的“偏出 (Partialling Out)”思想, 对式 (3) 两边同时求关于 X 的条件期望:

$$\mathbb{E}[Y | X] = \mathbb{E}[\theta_0(X) \cdot T + g_0(X) + \epsilon | X]$$

根据条件期望的线性性质, 将上式右侧展开:

$$\mathbb{E}[Y | X] = \mathbb{E}[\theta_0(X) \cdot T | X] + \mathbb{E}[g_0(X) | X] + \mathbb{E}[\epsilon | X]$$

此时, 应用条件期望的核心数理特性:

1. 条件常数化特性: 由于条件中已给定特征集合 X , 那么任何关于 X 的非参数函数值在条件期望算子中均等同于确定性常数。因此, 未知的动态弹性函数 $\theta_0(X)$ 与基准需求 $g_0(X)$ 均可直接提取到算子外部:

$$\mathbb{E}[\theta_0(X) \cdot T | X] = \theta_0(X) \cdot \mathbb{E}[T | X]$$

$$\mathbb{E}[g_0(X) | X] = g_0(X)$$

2. 外生性正交特性: 根据因果推断的强可忽略性假设, 结构误差项的条件期望为 0:

$$\mathbb{E}[\epsilon | X] = 0$$

将上述特性代入展开式, 并令 $l_0(X) = \mathbb{E}[Y | X]$ (即给定市场情境时酒店的预期对数销量水位), 同时已知, 我们最终得到常规规律下的期望供需方程:

$$l_0(X) = \theta_0(X) \cdot m_0(X) + g_0(X)$$

(4)

构造 FWL 残差方程

两式相减以消去混淆效应

用真实的原始因果结构方程式 (3) 减去历史常规期望方程式 (4):

$$Y - l_0(X) = (\theta_0(X) \cdot T + g_0(X) + \epsilon) - (\theta_0(X) \cdot m_0(X) + g_0(X))$$

由于复杂的非线性基准需求干扰 同时存在于两项中，在相减过程中被完全抵消。合并提取关于动态弹性 的项：

$$Y - l_0(X) = \theta_0(X) \cdot T - \theta_0(X) \cdot m_0(X) + \epsilon$$

$$Y - l_0(X) = \theta_0(X) \cdot (T - m_0(X)) + \epsilon$$

此时，我们正式引入弗里希-沃-洛维尔定理定义下的两个核心残差变量（Residuals）：

- 销量残差（Demand Surprise）： $W = Y - l_0(X)$ （代表排除了环境因素带来的大盘红利后，酒店需求的净异常震荡）。
- 价格残差（Price Shock）： $V = T - m_0(X)$ （代表排除了历史常规策略后，由于人为干预导致的净价格偏离）。

将 W 和 V 代入上式，最终完美推导出动态价格弹性的残差因果回归方程：

$$W = \theta_0(X) \cdot V + \epsilon \quad (5)$$

基于 R-learner 框架的工程落地求解

由于核心目标 $\theta_0(X)$ 是一个随市场状态、预订窗口动态变化的连续非参数函数，无法通过普通 OLS 求解。工程上遵循 R-learner（Residual Learner）框架，将残差回归方程式 (5) 转化为一个可以通过任意标准机器学习算法求解的加权均方误差优化问题：

$$\min_{\hat{\theta}} \mathbb{E} \left[\left(\hat{W} - \hat{\theta}(X) \cdot \hat{V} \right)^2 \right]$$

为了消除处理变量残差对损失函数梯度的不均匀干扰，将其提取并进行数学等价变形：

$$\min_{\hat{\theta}} \mathbb{E} \left[\hat{V}^2 \cdot \left(\frac{\hat{W}}{\hat{V}} - \hat{\theta}(X) \right)^2 \right]$$

2.2.2 基于深度强化学习的预期定价模型

传统酒店收益管理中，定价与库存去化节奏的跨期权衡始终是核心难题。传统定价模型往往过度聚焦于当前收益的最大化，却忽略了价格决策对未来库存消耗及长期收益的深远影响，使得早期定价过高极易导致后期库存积压与滞销损失，而早期定价过低又会错失旺季的高溢价红利。

这种跨期权衡的真正挑战在于真实市场的复杂性与多变性。所谓最优的定价策略并非一成不变，而是高度依赖当前所处的市场状态，同一定价在旺季可能过于保守而错失利润，在淡季却可能过于激进导致库存无人问津；面对大型活动需提价收割，遭遇竞品突袭则需跟降应

对。因此，真正有效的动态定价系统不能仅凭时间或库存等单一维度进行刻板决策，而必须具备敏锐感知并区分不同市场状态、进而采取差异化定价策略的能力。

为了在多变的环境中实现最优的跨期定价权衡，本研究构建了基于深度强化学习的动态定价模型，将酒店经营过程抽象为连续序贯决策问题，并专门打造了包含十四种典型市场状态的复杂仿真环境。在运行机制上，系统首先借助大模型动态识别当前所属的具体状态，随后仿真器依据定制化的数学模型进行数据增强与模拟采样，例如强需求状态下的负二项分布、价格战状态下的线性衰减泊松分布、库存积压状态下的阈值约束泊松分布等。为了引导智能体克服长周期决策中的短视倾向，并在销售早期便能精准前置预判并化解远期的库存积压风险，本研究引入了面向全局收益的动态惩罚机制，通过连续的每日持有成本与离散的期末滞销惩罚相结合，将剩余库存、入住日倒计时以及不同状态下的客流演变规律相融合，在时间轴上构建了随预订窗口收缩而动态递增的库存去化压力模型。

与传统先预测需求、再优化定价的两阶段方法相比，本研究摆脱了对人工经验规则和独立预测模型的依赖。智能体在与复杂仿真环境的持续自我博弈中，自主感知市场冷暖、评估库存压力并把握预订窗口节奏，最终在最大化长期回报的单一目标驱动下，自然涌现出能够完美适应各种复杂市场环境的差异化最优定价策略。

$$\lambda_t^{base} = base_demand \times seasonality_factor \times days_factor_t \times event_factor$$

base_demand（基础需求）：整个销售窗口的平均每日基准客流强度。

seasonality_factor（季节性因子）：模拟淡旺季整体需求差异（ > 1 ：旺季， < 1 ：淡季）。

days_factor_t（临期效应因子）：模拟"越临近入住日，客户搜索/预订行为越密集"的现实规律。

event_factor（事件因子）：。模拟大型会议、赛事、节假日等偶发事件对需求的冲击（ > 1 需求暴增， < 1 异常低迷）。

一、基础需求类 Regime

1. Normal (正常市场)

- 核心数学公式：

$$\lambda_t = \lambda_t^{base}$$

- 参数详细说明：
没有任何额外的市场偏移或情绪因子。
- 最终输出 / 采样逻辑：
直接进行泊松采样：

$$arrivals \sim Poisson(\lambda_t)$$

2. Strong Demand (强需求)

- 核心数学公式：
引入需求放大因子 与过度离散因子 。

$$\mu_t = k \times \lambda_t^{base}$$

- 参数详细说明：
 - $k \in [1.5, 3.0]$ ：基础需求放大倍数。
 - $r \in [2.0, 5.0]$ ：负二项分布的离散度（越小，方差越大，越容易出现极端“爆单”）。
 - 负二项分布的成功概率 $p_t = \frac{r}{r + \mu_t}$ 。
- 最终输出 / 采样逻辑：
从负二项分布中采样： $arrivals \sim NegativeBinomial(r, p_t)$ 。

3. Weak Demand (弱需求)

- 核心数学公式：

$$\lambda_t = \alpha \times \lambda_t^{base}$$

- 参数详细说明：
 - $\alpha \in [0.1, 0.4]$ ：需求衰减系数，表示市场大盘整体冷清。
- 最终输出 / 采样逻辑：
直接进行衰减后的泊松采样： $arrivals \sim Poisson(\lambda_t)$ 。（大量时间步 arrivals 会是 0）

二、事件驱动类 Regime

4. Spike (脉冲暴涨)

- 核心数学公式：

$$\lambda_t = \lambda_t^{base} + \alpha \times \exp(-\beta \times (t - t_{event}))$$

- 参数详细说明：
 - t_{event} ：突发事件发生的时间步（例如 $days_to_checkin = 30$ 时官宣演唱会）。
 - $\alpha \in [10.0, 50.0]$ ：脉冲的初始激发强度（可达基础流量的数十倍）。
 - $\beta \in [0.1, 0.5]$ ：热度衰减率。 β 越大，热度消散越快。只有当 $t \geq t_{event}$ 时激活此项。
- 最终输出 / 采样逻辑：
 $arrivals \sim Poisson(\lambda_t)$ 。流量呈现不对称的尖峰特征。

5. Fake Spike (假突破)

- 核心数学公式：

到达率 λ_t 同 Spike 过程（搜索量极大），但转化率 c_t 被极度压缩。

$$c_t = c_0 \times \exp(-\gamma \times \max(0, Price_t - Price_{base}))$$

- 参数详细说明：

- 基础转化率 c_0 极低（如0.01）。
- $\gamma \in [0.5, 2.0]$ ：对价格上涨的敏感度极高，价格稍微被情绪推高，转化率瞬间归零。

- 最终输出 / 采样逻辑：

先采样到达客户： $arrivals \sim Poisson(\lambda_t)$ （流量巨大）。

再采样实际订单： $bookings \sim Binomial(arrivals, c_t)$ （实际为 0 或极少）。

6. Collapse (崩盘)

- 核心数学公式：

$$\lambda_t = \begin{cases} \lambda_t^{base}, & t < t_{collapse} \\ \epsilon, & t \geq t_{collapse} \end{cases}$$

- 参数详细说明：

- $t_{collapse}$ ：灾难事件点（如封城指令下达日）。
- $\epsilon \in [0, 0.05]$ ：接近于 0 的残余需求。

- 最终输出 / 采样逻辑：

断崖式条件分支采样：事件发生后 $arrivals \sim Poisson(\epsilon)$ 。

三、竞争格局类 Regime

7. Price War (价格战)

- 核心数学公式：

需求量不再由基础模型决定，而是严格依赖相对价格。

$$\lambda_t = \lambda_t^{base} \times \left(1 - \eta \times \frac{Price_t - \min(Price_{competitors})}{Price_{base}} \right)$$

- 参数详细说明：

- $Price_{competitors}$ ：环境中的竞对价格数组。
- $\eta \in [2.0, 5.0]$ ：竞争价格弹性。自身价格比竞对每高出 1%，流量流失 η %。当 $Price_t > \min(Price_{competitors}) + \text{阈值}$ 时， $\lambda_t \rightarrow 0$ 。

- 最终输出 / 采样逻辑：

$arrivals \sim Poisson(\max(0, \lambda_t))$ 。逼迫 RL Agent 必须采取阶梯降价策略以获取流量。

8. Liquidity Dry (流动性枯竭)

- 核心数学公式：
买卖价差巨大，导致实际冻结。

$$\lambda_t = \lambda_t^{base} \times 1(|Price_t - Price_{market_expectation}| < \delta)$$

- 参数详细说明：
 - $Price_{market_expectation}$ ：买家的极低心理预期价。
 - δ ：买家容忍价差（通常很小）。
 - $1(\dots)$ 为指示函数，一旦卖家挂牌价高于买家预期，指标为 0。
- 最终输出 / 采样逻辑：
如果 Agent 不大幅降价至买家心理区间， $arrivals = 0$ 。

四、库存类 Regime

9. Scarcity (稀缺市场)

- 核心数学公式：
引入库存加速因子（Hazard function）。

$$ratio_sold_t = \frac{Total_Inventory - Inventory_Left_t}{Total_Inventory}$$

$$\lambda_t = \lambda_t^{base} \times \exp(\kappa \times (ratio_sold_t)^\phi)$$

- 参数详细说明：
 - $\kappa \in [1.0, 3.0]$ ：加速乘数极限。
 - $\phi \in [2.0, 4.0]$ ：形状参数。当库存售出比例 $ratio_sold_t$ 接近 1 时， $\exp$ 项指数级放大。
 - 同时，转化率函数中的价格弹性系数置为 0（买家对涨价不敏感）。
- 最终输出 / 采样逻辑：
 $arrivals \sim Poisson(\lambda_t)$ 。流量随库存减少加速上升。

10. Overstock (库存积压)

- 核心数学公式：
流量正常 $\lambda_t = \lambda_t^{base}$ ，但引入库存压力惩罚，强迫转化函数需要更低的价格。

$$pressure_t = \frac{Inventory_Left_t}{(days_to_checkin + 1) \times expected_daily_sales}$$

- 参数详细说明：
 - $pressure_t$ 衡量当前的去化进度。如果 > 1.5 ，说明严重滞销。

- 转化率门槛被提高：只有当 $Price_t \leq Price_{base} \times \exp(-\gamma \times (pressure_t - 1))$ 时，客户才愿意下单。

- 最终输出 / 采样逻辑：

到达采样正常 $arrivals \sim Poisson(\lambda_t)$ ，但 RL Agent 若不主动降低，则 $bookings = 0$ 。

五、时间压力类 Regime

11. Expiry Panic (临期踩踏)

- 核心数学公式：

一种非连续的跳跃过程。仅在时间边界触发。

$$Trigger = 1(days_to_checkin \leq 2 \wedge Inventory_Left_t > Safe_Threshold)$$

- 参数详细说明：

- 当 $Trigger = 1$ 时，市场正常价格体系崩溃。
- 此时只有提供跳水折扣 $Discount_t \sim Uniform(0.4, 0.6)$ （降价40%-60%），才能重新激发出 $\lambda_t = \lambda_t^{base} \times 5.0$ 的“捡漏”流量。

- 最终输出 / 采样逻辑：

判断时间边界，若满足则检测 Agent 的降价幅度。降价到位则爆发式采样泊松，否则 0 成交。

12. Early Calm (远期平静)

- 核心数学公式：

$$\lambda_t = \lambda_t^{base} \times 0.1$$

- 参数详细说明：

- 原有 $days_factor$ 在 $days_to_checkin$ 很大时仅衰减到。在 Early Calm 中，引入强制截断，远期乘数为。
- 买家行为极度平缓，没有任何事件因子干扰。

- 最终输出 / 采样逻辑：

$arrivals \sim Poisson(\lambda_t)$ 。输出大多为 0，偶尔为 1。

六、市场情绪类 Regime

13. FOMO (追涨)

- 核心数学公式：

引入动量因子 (Momentum Factor)，破坏原本的供需平衡（越涨越买）。

$$Momentum_t = \max(0, Price_{t-1} - Price_{t-2})$$

$$\lambda_t = \lambda_t^{base} \times \left(1 + \theta \times \frac{Momentum_t}{Price_{base}} \right)$$

- 参数详细说明：
 - $Momentum_t$ 为正向价格动量。
 - $\theta \in [5.0, 20.0]$ ：追涨敏感系数。如果 Agent 昨天涨价了，今天不仅转化率不降，到达率 反而按比例大幅拉升。
- 最终输出 / 采样逻辑：
 $arrivals \sim Poisson(\lambda_t)$ 。引导 RL Agent 发现“持续涨价能获得更高收益”的策略。

14. Fear (恐慌)

- 核心数学公式：
引入负动量冻结因子 (Negative Momentum Freeze)。

$$Neg_Momentum_t = \max(0, Price_{t-2} - Price_{t-1})$$

$$\lambda_t = \lambda_t^{base} \times \exp \left(-\phi \times \frac{Neg_Momentum_t}{Price_{base}} \right)$$

- 参数详细说明：
 - $Neg_Momentum_t$ 为降价幅度。
 - $\phi \in [10.0, 30.0]$ ：买跌恐慌系数。只要 Agent 降价（释放利空信号），客户观望情绪加重（认为明天还会降）， λ_t 呈指数级衰减。
- 最终输出 / 采样逻辑：
 $arrivals \sim Poisson(\lambda_t)$ 。此时如果 Agent 采取降价策略，反而会导致采样出 $arrivals = 0$ ，形成越降价越卖不出去的死局。

商业价值

行业现状是价格每天人工调整，很难满足新时代市场状态下对收益管理的要求。所以本项目通过落地验证这套技术方案在酒店集团的收益管理工作中能带来的：

- 收益提升程度
- 库存浪费下降比例
- 人工运营成本下降比例

2.2.3 基于价格歧视的库存分配定价模型

不同客户群体对价格的敏感程度存在显著差异。

例如：

- 商务客群通常更关注时间与便利性；
- 休闲客群通常更关注价格；
- 大型活动期间客群支付意愿显著提高。

因此，本研究将构建价格歧视（Price Differentiation）与库存分配联合优化模型。

在不同市场状态和需求条件下，系统动态决定：

- 哪些库存面向高价值客群；
- 哪些库存面向价格敏感客群；
- 不同客群采用何种价格策略。

该模型实现从单一价格优化向“价格+库存协同优化”升级，为酒店创造更高收益。

(待写)

2.3 库存管理模型（Inventory Allocation Models）

酒店房间库存具有明显时效性。未售出的房间在入住日之后即失去全部价值。因此，收益管理不仅要决定卖什么价格，还要决定什么时候卖、卖多少、保留多少。

本项目将根据价格空间是否受限，分别研究两类库存管理问题。

2.3.1 定价空间严格受限条件下的库存消耗速度优化

在实际经营中，酒店价格常受到渠道协议、品牌策略、OTA价格体系和市场竞争关系限制。在价格不能自由调整的情况下，收益优化的重点将从“调价”转向“控制库存消耗速度”。

本研究将基于远期供需预期、Booking Window识别和市场状态判断，建立库存消耗速度优化模型。系统将动态判断当前库存消耗是否过快或过慢，哪些日期应加速销售，哪些日期应保留库存，哪些日期存在未来涨价或高价值需求机会。

例如，在市场强需求且Booking Window提前出现时，系统可能建议放慢库存释放速度，避免过早卖断；在市场弱需求且窗口延迟时，系统可能建议提前释放部分库存降低滞销风险；在工作日与周末需求明显分化时，系统可能建议优先释放工作日库存，保留周五、周六库存等待更高价格机会。

该模型将帮助酒店在价格受限的现实条件下，通过库存节奏管理提升总收益。

(待写)

2.3.2 定价空间非严格受限条件下的库存分配优化

当酒店具有较大的价格调整空间时，库存管理问题将进一步扩展为库存分配问题。

本研究将结合价格歧视模型与需求预测模型，构建面向不同客群的库存分配优化框架。

系统将根据未来需求结构动态决定：

- 高价值客户库存比例；
- 普通客户库存比例；
- 提前预订库存比例；
- 临近入住库存比例。

该模型与价格歧视定价模型相互呼应，共同解决“有限房间应该卖给谁、什么时候卖、以什么价格卖”的问题。最终目标是在不确定需求下实现收益最大化，而不是简单追求入住率最大化。

(待写)

商业价值

酒店行业长期痛点是卖太快或者卖太晚，都会在收益上造成损失。项目落地后会验证 Inventory Allocation Models 技术方案在收益上：

- 库存滞销减少比例
- 卖断损失减少比例
- 房晚利用率提升比例

2.4 衍生价值与推广应用

2.4.1 向其他时效性库存行业推广

本项目虽然以酒店行业为核心应用场景，但其方法论具有较强的跨行业推广价值。酒店房晚、航空座位、高铁车票、邮轮舱位、演唱会门票和体育赛事门票都具有共同特征：库存过期即失效，需求高度不确定，价格需要动态调整，并且需要在不同客群之间进行库存配置。

因此，本项目形成的认知收益管理框架可进一步推广至航空、交通、邮轮、演唱会票务、体育赛事票务及各类本地活动运营场景。尤其是在香港大力发展会展经济、邮轮经济、演唱会经济和大型活动旅游的背景下，该技术体系具有较强的产业延展性。

酒店房晚、航空座位、高铁车票、邮轮舱位、演唱会门票及体育赛事门票均具有共同特征：

- 时效性库存；
- 需求不确定性；

- 动态定价需求；
- 库存分配问题。

因此，本项目形成的方法论和技术框架可进一步推广至航空、交通、票务及活动运营等领域。

(待写)

2.4.2 AI大模型驱动的行业智慧决策体系

本项目进一步探索 AI 大模型与收益管理 Learning & Inference 模型的结合机制，形成面向酒店经营者的智慧决策助手。

Learning & Inference 模型负责计算和优化，包括市场状态识别、事件影响评估、价格弹性计算、库存优化和动态定价策略生成。AI 大模型则负责解释、交互和知识沉淀，帮助运营人员理解系统为什么给出某一策略，并支持人机协同决策。系统最终能够以自然语言形式向酒店经营者解释：

当前市场处于什么状态；

需求变化主要由什么因素驱动；

当前价格是否偏高或偏低；

库存是否存在滞销或卖断风险；

建议采取何种定价和库存释放策略；

该策略背后的风险和收益权衡是什么。

通过这种方式，本项目将形成可解释、可交互、可持续学习的新一代酒店智慧决策体系，实现从“模型给结果”到“系统辅助经营判断”的升级。

场景 1：海岛暑期旺季，市场过热

背景：我们包了三亚海棠湾某酒店 7 月 15-30 日每天 5 间房，成本价 800 元 / 间，往年客人提前 30 天开始预订，今年 6 月 9 日（提前 36 天）已经开始有订单，且同区域酒店陆续满房，OTA 价格持续上涨。

步骤	引擎名称	核心任务	AI 产出
Step1	市场状态引擎	识别当前市场 Regime 市场正在发生什么？ 技术：HMM / Bayesian Network 输出：当前属于 Strong / Weak / Spike / Scarcity ...	「区域级强需求 + 酒店级 FOMO 追涨」 完整 Regime 世界观（14 大市场状态）  宏观层：三亚暑期客流同比 + 40%，航班量暴增； 区域层：海棠湾整体酒店库存去化率 80%，属于强需求； 酒店层：同价位竞品全部售罄，客人出现“怕订不到”的追涨行为，属于 FOMO 追涨状态。
Step2	窗口识别引擎	判断 Booking Window 客户什么时候开始预订？ 技术：Survival / Hazard Model 输出： Window提前？ Window延迟？ Window缩短？	「预订窗口提前开启，且窗口被拉长」 往年提前 30 天进入预订高峰，今年提前 36 天就出现订单，说客人愿意更早预订，预订窗口从“提前 30-7 天”拉长到“提前 43 天”，当前正处于窗口早期，市场热度会持续走高。
Step3	库存风险引擎	评估库存风险 库存是风险还是机会？ 技术：OR 输出： Sell-out Risk Unsold Risk	「低库存风险，无甩货压力」 当前入住率 10%，但同区域酒店去化率超 80%，且未来 3 周将增酒店开业，库存缺口会持续扩大，不存在卖不掉的风险，反而卖太早、卖太便宜的风险。
Step4	热度判定	酒店 / 区域热度	「区域级过热、单酒店热」

	断引擎	为什么热？ 技术：Causal AI 输出： Region Hot ? Hotel Hot ?	不是我们包的这家酒店单独火，是整个海棠湾 7 月中旬全区域房，属于系统性供需失衡，热度会传导到我们的库存上。
Step5	溢价引擎	客人最高接受溢价 客户愿意支付多少？ 技术：Demand Curve / Elasticity Model 输出： 1000→1500接受度？ 1000→3000接受度？	「可接受 2.5 倍溢价，上限 2000 元 / 间」 历史订单数据显示，该酒店同房型在区域无房时，客人愿意接受高 2.5 倍的溢价（成本 800 元，最高可卖 2000 元），且价格敏感度下降，涨价不会明显抑制订单。
Step6	决策引擎	定价 + 库存释放 技术：Reinforcement Learning + OR 输出： —— Hold —— 正常售卖 —— 亏损出货 —— 高利润模式	选择策略：高额利润模式 1. 定价：当前挂牌价 1800 元 / 间（高于 OTA 当前价 1600 元），每周根据区域库存剩余情况上调 5%-10%，最高不超过 2000 元； 2. 库存：工作日和周末全部 hold 3-4 间，仅少量放货测试市场等区域库存进一步耗尽后，再分批次高价放出； 3. 控制：设置单晚销售上限，避免某一天卖断，保持“持续有房但库存紧张”的状态，维持追涨情绪。

英文版

Background and Strategic Significance

The global tourism industry is entering a new phase characterized by high volatility, dynamic customer behavior, and increasingly complex demand patterns. Traditional Revenue Management Systems (RMS), which rely primarily on historical sales forecasting, are becoming insufficient for supporting modern hospitality operations.

Meanwhile, China's continued expansion of visa-free entry policies and the rapid recovery of international tourism are creating unprecedented opportunities for Hong Kong as an international tourism hub and a strategic gateway within the Guangdong-Hong Kong-Macao Greater Bay Area.

According to Hong Kong Tourism Blueprint 2.0, tourism contributed approximately 2.8% of Hong Kong's GDP and supported nearly 160,000 jobs in 2024. Visitor arrivals recovered to around 45 million in 2024, representing a 31% year-on-year increase. The industry is now shifting from post-pandemic recovery toward high-quality growth.

However, tourism demand today is increasingly influenced by large-scale events, social media sentiment, transportation conditions, weather disruptions, and rapidly changing consumer behaviors. Market dynamics can no longer be adequately understood through historical booking data alone.

This project proposes a next-generation Market State Operating System for hospitality and tourism industries.

Instead of merely forecasting future demand, the proposed system aims to understand:

- What is happening in the market?
- Why is it happening?
- How customer willingness-to-pay is evolving?
- How inventory should be allocated under uncertainty?
- What is the optimal long-term revenue strategy?

The system integrates five complementary AI capabilities:

- Regime Intelligence for market-state recognition;

- Causal AI for market interpretation;
- Price Elasticity Modeling for willingness-to-pay estimation;
- Operations Research for constrained inventory optimization;
- Reinforcement Learning for dynamic revenue decision-making.

Together, these capabilities establish a new paradigm that transforms traditional forecasting systems into intelligent decision systems for hospitality and tourism operations.

Beyond hotels, the proposed framework can be generalized to airlines, railways, cruise operators, event ticketing, and other perishable-inventory industries, creating a scalable AI infrastructure for the future service economy.

The project will strengthen Hong Kong's position as a leading hub for TravelTech innovation, while providing accessible revenue management capabilities to SMEs and advanced decision-support tools to large hospitality enterprises across Hong Kong and the Greater Bay Area.